HETIC · GIVAUDAN AI CHALLENGE · GR12_HEXA

Benchmark des modèles Ollama

Assistant RAG sur les données publiques de Givaudan — tests réalisés le 10/11/2026 sur le poste de développement de l'équipe.

Recommandation. Pour le chatbot « Trouver mon parfum », nous retenons **qwen2.5:3b** comme modèle de génération et **nomic-embed-text** comme modèle d'embeddings. qwen2.5:3b obtient le meilleur score global (97 % : 31 questions sur 32 justes et 4 pièges sur 4 refusés) pour 2,2 Go de RAM. Surtout, il n'a **jamais inventé** de réponse, ce qui est essentiel pour ne pas proposer un parfum ou une note qui n'existe pas. Seul llama3.2:3b fait aussi bien sur ce point, mais il est moins juste et plus lent. Son seul défaut est la vitesse : environ 21 s par réponse sur notre PC sans GPU. nomic-embed-text retrouve le bon passage en 1re position dans 94 % des cas, tout en étant le plus léger des modèles d'embeddings testés (0,27 Go).

1. Objectif et mission

Notre projet de hackathon est un chatbot « **Trouver mon parfum** ». L'utilisateur clique sur un bouton, règle des curseurs (plus chaleureux, plus frais, etc.), et l'application affiche des propositions de parfums sur trois colonnes. Le chatbot doit comprendre la demande de l'utilisateur, s'appuyer sur des données fiables et expliquer ses propositions en français.

Nous avons construit une première version technique : un assistant RAG (Retrieval-Augmented Generation). Il retrouve les passages pertinents dans une base de connaissances (ChromaDB), puis demande à un modèle de langage local (Ollama) de répondre **uniquement** à partir de ces passages. Pour ce benchmark, la base contient un dossier de 14 chapitres sur Givaudan (histoire, résultats 2024 à 2026, stratégie 2030, durabilité, divisions Fragrance & Beauty et Taste & Wellbeing), découpé en 35 morceaux d'environ 800 caractères.

Ce benchmark répond à une question précise : quels modèles Ollama, qui tournent en local sans service payant, sont assez justes, assez honnêtes et assez rapides pour notre mission, sur le matériel dont nous disposons ?

2. Protocole de test

Matériel. PC Microsoft Surface, processeur AMD Ryzen 5, 7,5 Go de RAM, **sans GPU** : tous les calculs se font sur le processeur. Ollama version 0.40.16.

Questions. 36 questions en français. 32 ont une réponse dans le dossier : chiffres financiers, dates, noms, régions. 4 sont des **pièges** sans réponse dans le dossier : salaire du CEO, cours de bourse du jour, nombre de brevets en 2025, chiffre d'affaires 2027. Sur un piège, un bon modèle doit dire que l'information manque au lieu d'inventer.

Notation automatique. Une réponse est juste si le chiffre ou le nom attendu y figure (par exemple « 7 472 » pour le chiffre d'affaires 2025). Les écritures comme « 7472 » ou « 7 472 » sont acceptées. Un piège est réussi si la réponse contient un refus explicite (« le dossier ne précise pas », « je n'ai pas trouvé d'information », etc.).

Conditions identiques pour tous les modèles. Même prompt système (« réponds uniquement à partir des extraits, n'invente jamais de chiffre »), température 0 pour des résultats reproductibles, contexte de 4096 tokens. Chaque modèle reçoit exactement les mêmes 4 passages par question,

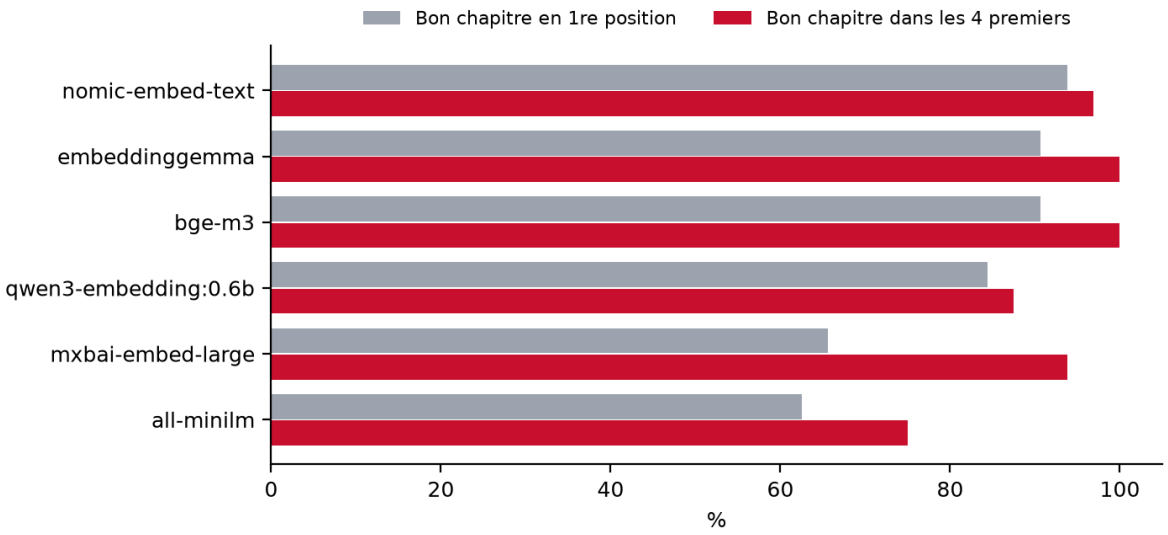
retrouvés avec nomic-embed-text. Les écarts mesurés viennent donc uniquement du modèle de génération.

Mesures. Justesse sur les 32 questions, taux de refus sur les 4 pièges, score global sur les 36 questions, temps de réponse médian (modèle déjà chargé en mémoire), vitesse de génération (tokens par seconde), RAM occupée par le modèle chargé et taille sur disque.

3. Modèles d'embeddings (recherche des passages)

Le modèle d'embeddings transforme le texte en vecteurs pour retrouver les passages proches de la question. Si la recherche se trompe de passage, même le meilleur LLM ne peut pas répondre juste. Pour chacune des 32 questions avec réponse, nous regardons si un passage du bon chapitre arrive en 1re position (Top-1) et dans les 4 premiers (Top-4, ce qui est réellement envoyé au LLM). Le MRR (Mean Reciprocal Rank) résume le classement : 1 signifie toujours en 1re position.

Modèle	Taille	Top-1	Top-4	MRR	Indexation (35 morceaux)	Requête
nomic-embed-text	0,27 Go	94 %	97 %	0,959	15,86 s	72,8 ms
embeddinggemma	0,62 Go	91 %	100 %	0,953	17,92 s	64,2 ms
bge-m3	1,16 Go	91 %	100 %	0,945	38,37 s	125,8 ms
qwen3-embedding:0.6b	0,64 Go	84 %	88 %	0,869	54,1 s	271 ms
mxbai-embed-large	0,67 Go	66 %	94 %	0,796	37,26 s	172,6 ms
all-minilm	0,05 Go	62 %	75 %	0,72	2,71 s	18,3 ms



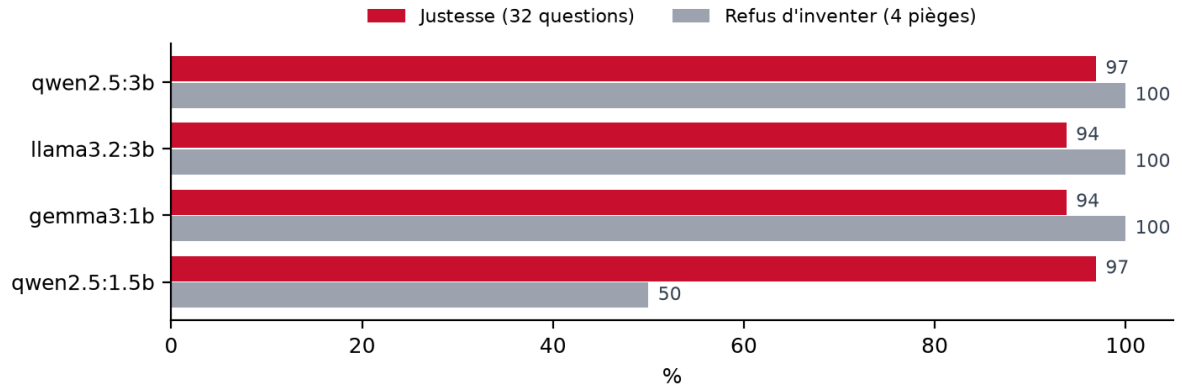
nomic-embed-text a le meilleur Top-1 (94 %) et le meilleur MRR (0,96). C'est aussi le plus léger des modèles performants (0,27 Go) et l'un des plus rapides. **embeddinggemma** et **bge-m3** trouvent le bon chapitre dans les 4 premiers passages dans 100 % des cas, mais moins souvent en 1re position, et bge-m3 pèse quatre fois plus lourd. bge-m3, conçu pour le multilingue, reste une bonne alternative si nos fiches parfum sont rédigées en plusieurs langues. mxbai-embed-large, qwen3-embedding:0.6b et surtout all-minilm (75 % en Top-4, modèle surtout entraîné sur l'anglais) sont nettement moins bons sur nos questions en français. *Note : les temps d'indexation de bge-m3, qwen3-embedding, embeddinggemma et all-minilm ont été mesurés pendant qu'un autre test tournait sur la machine. Ils sont donc légèrement surestimés, mais les scores de recherche ne sont pas affectés.*

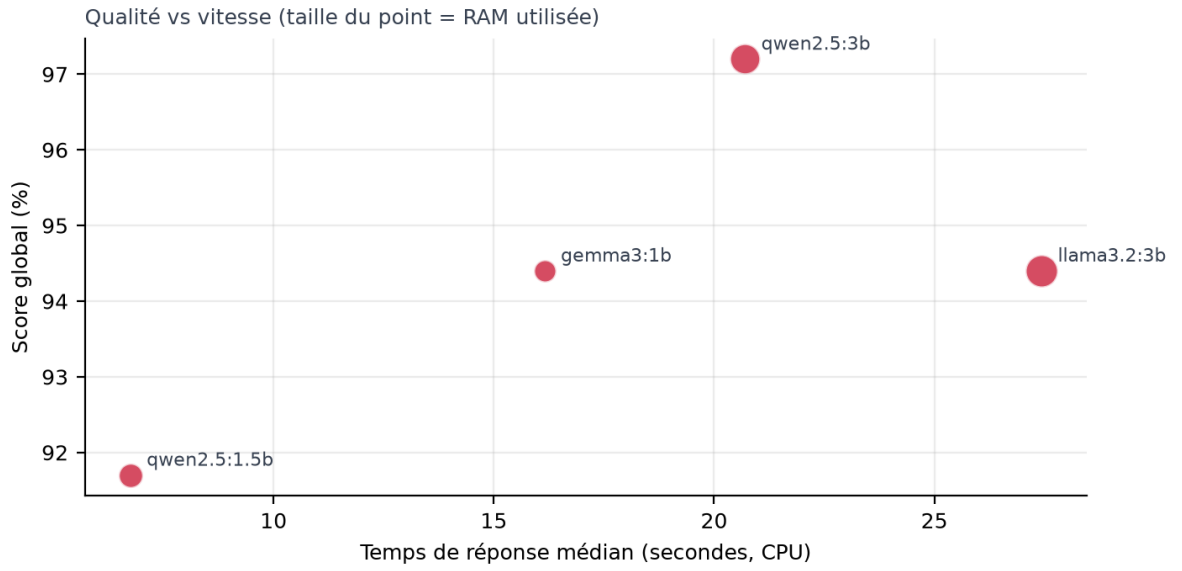
4. Modèles de génération (LLM)

Nous avons testé complètement 4 modèles de génération de 1 à 3 milliards de paramètres, adaptés à 7,5 Go de RAM. Un cinquième, **qwen3:4b**, a été testé sur 3 questions seulement. Il a répondu juste, mais en 99 à 169 secondes par réponse, parce que son mode « réflexion » restait actif (il écrit d'abord son raisonnement en anglais). Nous l'avons écarté comme trop lent pour un chatbot sur ce matériel. Les modèles de 7 à 8 milliards de paramètres (mistral:7b, qwen2.5:7b, llama3.1:8b) n'ont pas été testés : ils dépassent ce que notre PC peut faire tourner confortablement, et le réseau de l'école ne permettait pas de les télécharger dans le temps imparti.

Modèle	Disque	RAM	Justesse (/32)	Refus pièges (/4)	Score global	Temps médian	Vitesse
qwen2.5:3b	1,93 Go	2,17 Go	97 % (31)	100 % (4)	97 %	20,7 s	12,4 tok/s
gemma3:1b	0,81 Go	0,88 Go	94 % (30)	100 % (4)	94 %	16,15 s	19,7 tok/s
llama3.2:3b	2,02 Go	2,57 Go	94 % (30)	100 % (4)	94 %	27,43 s	8,6 tok/s
qwen2.5:1.5b	0,99 Go	1,17 Go	97 % (31)	50 % (2)	92 %	6,75 s	21,6 tok/s

Ligne verte : meilleur score global (à égalité, le plus rapide). Vitesse = tokens générés par seconde (médiane). Temps médian = question posée → réponse complète, modèle déjà chargé.





5. Analyse

qwen2.5:3b — le plus fiable

97 % de justesse, 4 pièges sur 4 refusés, score global de 97 %. Il n'a **jamais inventé** (comme llama3.2:3b) : sur la seule question qu'il a ratée, il a répondu « Le dossier ne le précise pas » au lieu de donner un faux chiffre. Il utilise 2,2 Go de RAM et répond en environ 21 s (12 tokens/s). C'est notre choix pour la qualité.

qwen2.5:1.5b — le plus rapide, mais il invente

97 % de justesse et de loin le plus rapide : 6,8 s par réponse, 22 tokens/s, 1,2 Go de RAM. Mais il échoue sur 2 pièges sur 4 en inventant des réponses, comme « Le cours de l'action Givaudan aujourd'hui est de 15 CHF » ou un chiffre d'affaires 2027 de « 6 478 millions de CHF ». Il invente aussi un « 12,3 % » pour la croissance du 3e trimestre 2026. Pour un chatbot qui recommande des parfums, ce comportement pourrait faire proposer des produits ou des notes qui n'existent pas.

gemma3:1b — honnête et très léger

94 % de justesse, 4 pièges sur 4 refusés, seulement 0,9 Go de RAM. C'est une bonne option de secours sur une machine très limitée. Il commet deux erreurs : une région confondue (Asie-Pacifique au lieu de SAMEA) et un chiffre inventé (6,8 % au 3e trimestre 2026). Malgré sa petite taille, il est plus lent que qwen2.5:1.5b sur notre PC (16 s par réponse).

llama3.2:3b — correct mais le plus lent

94 % de justesse et 4 pièges sur 4 refusés. Il n'invente pas, mais il refuse parfois à tort : sur la date du rachat par Roche, il répond que l'information « ne se trouve pas dans les extraits » alors qu'elle y figure. C'est le plus lent (27 s par réponse, 8,6 tokens/s) et le plus gourmand en RAM (2,6 Go), pour une qualité inférieure à qwen2.5:3b.

Un point faible de la recherche, pas des modèles

La question sur la croissance du 3e trimestre 2026 a été ratée par **tous** les modèles. La cause n'est pas le LLM : nomic-embed-text n'a pas remonté le bon passage, intitulé « Ventes des neuf premiers mois de 2026 ». Les mots de la question (« troisième trimestre ») ne ressemblent pas assez à ceux du texte. Ce cas montre bien la différence entre les modèles : qwen2.5:3b et llama3.2:3b reconnaissent qu'ils ne savent pas, alors que qwen2.5:1.5b et gemma3:1b inventent un chiffre. Pour corriger le problème, on peut envoyer plus de passages (Top-6), ajouter des mots-clés dans les fiches, ou combiner recherche vectorielle et recherche par mots-clés.

6. Recommandation pour la mission

Modèle de génération : qwen2.5:3b. C'est le meilleur compromis entre justesse et honnêteté. Pour un produit qui conseille des parfums, un modèle qui dit « je ne sais pas » vaut mieux qu'un modèle rapide qui invente.

Modèle d'embeddings : nomic-embed-text, avec bge-m3 en alternative si le catalogue de parfums est multilingue.

Architecture conseillée pour « Trouver mon parfum ». Les curseurs (chaleureux, frais, etc.) ne doivent pas passer par le LLM. Chaque parfum du catalogue reçoit une note sur chaque axe, et le code calcule les propositions les plus proches des curseurs : c'est instantané, fiable et vérifiable. Le LLM n'intervient que pour deux tâches : transformer une demande libre (« un parfum léger pour l'été ») en valeurs de curseurs au format JSON, et rédiger une courte explication pour chaque proposition. Il ne choisit que parmi les parfums fournis par le code, ce qui évite qu'il en invente.

Vitesse pour la démo. Sur notre PC sans GPU, qwen2.5:3b met environ 20 s par réponse. Pour la démo, il faut générer les trois explications en un seul appel, afficher la réponse au fur et à mesure (streaming), ou faire tourner Ollama sur une machine équipée d'un GPU, où le même modèle répond en quelques secondes. En dernier recours, qwen2.5:1.5b est 3 fois plus rapide, à condition de vérifier dans le code que chaque parfum cité existe bien dans le catalogue.

7. Limites du benchmark

• 36 questions seulement, sur un seul dossier (Givaudan) : les écarts de 1 ou 2 questions entre modèles ne sont pas statistiquement significatifs.

• La notation est automatique, par mots-clés : une réponse juste mais formulée autrement (par exemple « 7,5 milliards » au lieu de « 7 472 millions ») serait comptée fausse. Nous avons relu les erreurs, ce qui nous a fait corriger une fois la détection des refus.

• Les tests ont été faits sur un seul PC, sans GPU : les temps absolus seraient beaucoup plus courts sur une machine avec GPU. La justesse, elle, ne dépend pas du matériel.

• Le début du test de qwen2.5:1.5b s'est déroulé en même temps que la fin du test des embeddings : son temps de réponse est peut-être un peu surestimé. Il reste le plus rapide.

• Les modèles de 7 milliards de paramètres et plus n'ont pas été testés (limite de RAM et de réseau). Ils devraient être évalués sur une machine plus puissante.

• Le benchmark porte sur des questions factuelles. Il faudra le compléter avec les vraies tâches du chatbot parfum : conversion de demandes en curseurs (JSON) et qualité des explications.

Annexe A — Résultat par question

✓ = réponse correcte (chiffre ou nom attendu présent ; pour les 4 pièges, refus explicite). ✗ = réponse fausse, incomplète ou inventée.

#	Question	qwen2.5 : 3b	gemma3 : 1b	llama3.2 : 3b	qwen2.5 : 1.5b
1	Quel a été le chiffre d'affaires de Givaudan en 2025 ?	✓	✓	✓	✓
2	Quelle a été la croissance like-for-like de Givaudan en 2025 ?	✓	✓	✓	✓
3	Quel dividende par action Givaudan propose-t-il pour l'exercice 2025 ?	✓	✓	✓	✓
4	Qui est le CEO de Givaudan depuis mars 2026 ?	✓	✓	✓	✓
5	En quelle année Givaudan a-t-elle été fondée ?	✓	✓	✓	✓
6	Quelle a été la croissance de la parfumerie fine (Fine Fragrance) en 2025 ?	✓	✓	✓	✓
7	Quel était le bénéfice net de Givaudan au premier semestre 2026 ?	✓	✓	✓	✓
8	En quelle année Givaudan vise-t-elle le net zéro sur sa chaîne de valeur ?	✓	✓	✓	✓
9	Qui sont les principaux concurrents de Givaudan ?	✓	✓	✓	✓
10	Quel était le chiffre d'affaires de Givaudan sur les neuf premiers mois de 2026 ?	✓	✓	✓	✓
11	Quel était le ratio dette nette sur EBITDA de Givaudan à fin 2025 ?	✓	✓	✓	✓
12	Quel était l'EBITDA de Givaudan en 2025 ?	✓	✓	✓	✓
13	Quel a été le free cash flow de Givaudan en 2025 ?	✓	✓	✓	✓
14	Quel était le chiffre d'affaires de la division Fragrance & Beauty en 2025 ?	✓	✓	✓	✓
15	Quel était le chiffre d'affaires de la division Taste & Wellbeing en 2025 ?	✓	✓	✓	✓
16	Quelle région a le plus progressé dans la division Taste & Wellbeing en 2025 ?	✓	✗	✓	✓
17	En quelle année Roche a-t-il racheté Givaudan ?	✓	✓	✗	✓
18	En quelle année Givaudan a-t-elle été séparée de Roche et cotée en bourse ?	✓	✓	✓	✓
19	Quelle société Givaudan a-t-elle rachetée en 2007 ?	✓	✓	✓	✓
20	Dans quelle ville se trouve le siège de Givaudan ?	✓	✓	✓	✓
21	Combien d'employés Givaudan comptait-elle à fin 2025 ?	✓	✓	✓	✓
22	Quelle a été la croissance like-for-like de Givaudan au troisième trimestre 2026 ?	✗	✗	✗	✗
23	Depuis quelle année toute l'électricité de Givaudan est-elle renouvelable ?	✓	✓	✓	✓
24	Quel pourcentage des postes de direction est occupé par des femmes chez Givaudan ?	✓	✓	✓	✓
25	Quel est l'objectif de croissance des ventes de la stratégie 2030 de Givaudan ?	✓	✓	✓	✓
26	Quelle a été la croissance moyenne des ventes de Givaudan sur la période 2021-2025 ?	✓	✓	✓	✓
27	Quel était le chiffre d'affaires de Givaudan en 2024 ?	✓	✓	✓	✓
28	En quelle année Givaudan a-t-elle racheté Naturex ?	✓	✓	✓	✓
29	Quelle était la dette nette de Givaudan au 30 juin 2026 ?	✓	✓	✓	✓
30	Quelle était la marge EBITDA ajustée de Givaudan au premier semestre 2026 ?	✓	✓	✓	✓
31	Quel était le chiffre d'affaires de la région Asie-Pacifique au premier semestre 2026 ?	✓	✓	✓	✓

#	Question	qwen2.5 : 3b	gemma3 : 1b	llama3.2 : 3b	qwen2.5 : 1.5b
32	De combien Givaudan a-t-elle réduit ses émissions des scopes 1 et 2 par rapport à 2015 ?	✓	✓	✓	✓
33	Quel est le salaire annuel du CEO de Givaudan ? *(piège)*	✓	✓	✓	✓
34	Quel est le cours de l'action Givaudan aujourd'hui ? *(piège)*	✓	✓	✓	✗
35	Combien de brevets Givaudan a-t-elle déposés en 2025 ? *(piège)*	✓	✓	✓	✓
36	Quel sera le chiffre d'affaires de Givaudan en 2027 ? *(piège)*	✓	✓	✓	✗

Annexe B — Exemples de réponses

Piège : « Quel est le cours de l'action Givaudan aujourd'hui ? »

qwen2.5:3b : « Le cours de l'action Givaudan n'est pas fourni dans les extraits du dossier Givaudan. » ✓
gemma3:1b : « Le dossier ne précise pas le cours de l'action Givaudan aujourd'hui. » ✓
llama3.2:3b : « Je n'ai pas accès à des informations en temps réel sur le cours de l'action Givaudan. Le dossier que j'ai consulté ne fournit pas d'informations sur le cours actuel de l'action Givaudan. » ✓
qwen2.5:1.5b : « Le cours de l'action Givaudan aujourd'hui est de 15 CHF par action. » ✗ *(inventé)*

Passage non retrouvé : « Quelle a été la croissance like-for-like de Givaudan au troisième trimestre 2026 ? » (réponse attendue : 8,6 %)

qwen2.5:3b : « Le dossier ne le précise pas. » *(honnête)*
llama3.2:3b : « Je n'ai pas trouvé d'information sur la croissance like-for-like de Givaudan au troisième trimestre 2026 dans les extraits du dossier fournis. » *(honnête)*
gemma3:1b : « La croissance like-for-like (LFL) de Givaudan au troisième trimestre 2026 était de 6,8 %. » *(inventé)*
qwen2.5:1.5b : « […] était de 12,3 %, ce qui correspond à une croissance de 12,3 millions de CHF sur un chiffre d'affaires de 7 412 millions de CHF. » *(inventé)*

Question réussie par tous : « Qui sont les principaux concurrents de Givaudan ? »

Les quatre modèles citent correctement dsm-firmenich, IFF et Symrise, avec leur pays.

Annexe C — Reproduire le benchmark

Le code du benchmark est dans le dossier **benchmark/** du repo : **questions.py** (questions et réponses attendues), **bench.py** (exécution des tests), **rescore.py** (recalcul des scores), **make_pdf.py** (génération de ce document) et **results/** (toutes les réponses brutes en JSON).

Commandes, depuis la racine du projet avec l'environnement virtuel activé : **python benchmark/bench.py embed nomic-embed-text bge-m3**, puis **python benchmark/bench.py llm --embed nomic-embed-text qwen2.5:3b**, et enfin **python benchmark/make_pdf.py**.